

Universidad Católica de Colombia
Facultad de Ingeniería
Ingeniería de Sistemas

**Análisis Predictivo y Estadístico de la
Severidad de Accidentes de Tránsito
mediante Técnicas de Analítica de Datos y
Python**

Trabajo Final de Curso — Analítica de Datos

Estudiante:

Juan Carlos Sánchez Martínez

Alvaro Felipe Lopez Russi

Sebastian Felipe Baracaldo Amado

Docente:

Curso de Analítica de Datos

Bogotá, Mayo de 2026

Dataset: 02_04_crash_severity.csv — 60 000 registros — 27 variables
Herramientas: Python 3, Jupyter Notebook, pandas, scikit-learn, scipy, seaborn

Índice

1. Introducción

La analítica de datos se ha convertido en uno de los pilares fundamentales de la Ingeniería de Sistemas moderna. Las organizaciones públicas y privadas toman decisiones estratégicas basadas en información cuantitativa extraída de grandes volúmenes de datos. Sin embargo, el verdadero valor de los datos no radica en almacenarlos o visualizarlos, sino en *interpretarlos críticamente*, comprender sus patrones y transformar los resultados en conocimiento útil para la toma de decisiones.

El presente trabajo integra los temas desarrollados durante el curso: estadística descriptiva, captura y limpieza de datos, análisis exploratorio, KPI's, pruebas de hipótesis, pruebas paramétricas y no paramétricas, ANOVA, regresión múltiple y regresión logística. El objetivo es desarrollar una solución analítica completa utilizando Python como lenguaje principal.

El dataset contiene información sobre accidentes de tránsito y variables asociadas a la severidad del accidente: presencia de motocicletas, bicicletas, peatones, embriaguez, huecos, transporte público, entre otros factores. Más allá de ejecutar código o generar gráficos, este trabajo desarrolla **pensamiento crítico analítico**: cada prueba estadística se interpreta desde una perspectiva técnica, social y ética.

2. Planteamiento del Problema

Las ciudades modernas enfrentan desafíos complejos relacionados con la movilidad urbana y la seguridad vial. El aumento del parque automotor, el crecimiento demográfico y las deficiencias en infraestructura generan escenarios donde los accidentes de tránsito representan una problemática social, económica y de salud pública.

Las autoridades requieren herramientas analíticas que permitan identificar patrones en los accidentes más graves, predecir factores de riesgo y diseñar políticas públicas basadas en evidencia. La entidad gubernamental que suministra el dataset requiere un análisis integral del comportamiento de la accidentalidad registrada.

El problema central puede formularse así: *¿Qué variables presentes en el registro de accidentes se asocian significativamente con la severidad del siniestro, y en qué medida es posible construir un modelo predictivo confiable a partir de ellas?*

Este problema tiene dos dimensiones. La primera es **estadística**: identificar qué factores tienen asociación demostrable con la gravedad. La segunda es **social**: los factores con mayor peso analítico deben interpretarse en su contexto de movilidad, inequidad territorial y capacidad institucional de respuesta.

3. Objetivos

Objetivo General

Desarrollar un sistema completo de análisis estadístico y predictivo en Python que permita identificar factores asociados a la severidad de accidentes de tránsito mediante técnicas de analítica descriptiva, inferencial y modelos de regresión.

Objetivos Específicos

1. Realizar procesos de captura, limpieza y transformación de datos.
2. Aplicar estadística descriptiva para comprender el comportamiento general del dataset.
3. Diseñar KPI's relevantes para la interpretación de la accidentalidad.
4. Validar supuestos estadísticos mediante pruebas de normalidad.
5. Aplicar pruebas de hipótesis paramétricas y no paramétricas.
6. Implementar análisis ANOVA para comparar grupos territoriales.
7. Construir modelos de regresión múltiple y logística.
8. Interpretar críticamente los resultados obtenidos.
9. Elaborar conclusiones orientadas a la toma de decisiones.
10. Documentar el proceso analítico utilizando estándares técnicos.

4. Marco Analítico y Estadístico

El análisis se apoya en los siguientes fundamentos estadísticos:

Estadística descriptiva. Las medidas de tendencia central (media, mediana) y dispersión (desviación estándar, rango intercuartílico) describen la distribución de las variables. En distribuciones asimétricas, la mediana es preferible a la media como medida robusta.

Pruebas de hipótesis. La prueba chi-cuadrado de independencia evalúa si dos variables categóricas están asociadas. El coeficiente V de Cramér cuantifica la fuerza de esa asociación ($V \in [0, 1]$, donde valores $> 0,3$ indican efecto moderado a grande). Para diferencias de medias/distribuciones se emplean la prueba t de Welch (si se cumple normalidad aproximada) y Mann-Whitney U (no paramétrica).

ANOVA. Permite comparar medias entre tres o más grupos. Si se rechaza la hipótesis nula (F significativo), las comparaciones post-hoc identifican qué pares de grupos difieren.

Regresión múltiple. Modela una variable respuesta continua como función lineal de varios predictores. El coeficiente R^2 indica la proporción de varianza explicada.

Regresión logística. Estima la probabilidad de un evento binario. Los coeficientes se interpretan como log-odds; el AUC-ROC mide la capacidad discriminativa.

Diferencia entre significancia estadística y práctica. Con $n = 60\,000$, cualquier diferencia trivial puede ser significativa ($p < 0,05$). Por ello, siempre se complementa el p -valor con el tamaño del efecto (V de Cramér, r rank-biserial, R^2).

5. Metodología

El proyecto sigue once fases sucesivas, cada una construida sobre los resultados de la anterior:

1. **FASE 1 — Comprensión del Dataset:** carga, identificación de dimensiones, tipos de variables, nulos e inconsistencias.

2. **FASE 2 — Limpieza y Transformación:** tratamiento de nulos, decisión sobre duplicados, codificación y creación de variables derivadas.
3. **FASE 3 — Estadística Descriptiva:** medidas de tendencia central, dispersión, distribuciones, histogramas, boxplots, tablas dinámicas y correlaciones.
4. **FASE 4 — KPI's y Previsión:** diseño y visualización de indicadores clave de rendimiento.
5. **FASE 5 — Normalidad:** pruebas Shapiro-Wilk e histogramas para validar supuestos paramétricos.
6. **FASE 6 — Pruebas de Hipótesis:** formulación de hipótesis, chi-cuadrado y tamaños de efecto.
7. **FASE 7 — Pruebas t :** comparación de grupos mediante prueba t independiente de Welch.
8. **FASE 8 — Wilcoxon y Mann-Whitney:** comparaciones no paramétricas cuando no se cumple normalidad.
9. **FASE 9 — ANOVA:** comparación de severidad entre localidades.
10. **FASE 10 — Regresión Múltiple:** modelo predictivo lineal con selección de variables.
11. **FASE 11 — Regresión Logística:** clasificador binario (grave/no grave) con evaluación de métricas.

Todo el código fue desarrollado en Python 3 con Jupyter Notebook. Las librerías utilizadas incluyen `pandas`, `numpy`, `matplotlib`, `seaborn`, `scipy.stats` y `scikit-learn`.

6. Limpieza y Preparación de Datos

6.1. Comprensión del Dataset (FASE 1)

El dataset cargado contiene **60 000 filas** y **27 columnas**. Las variables se clasifican en:

- **Cualitativas nominales:** Localidad, Clase_Acc, Dia_Semana_Acc, Elemento_Choque.
- **Cualitativa ordinal:** Gravedad_Indicador_Tradicional (Solo Daños < Con Heridos < Con Muertos).
- **Variables binarias (Con_*):** 22 indicadores de condición (0 = No, 1 = Sí): Con_Bicicleta, Con_Carga, Con_Embriaguez, Con_Huecos, Con_Menores, Con_Moto, Con_Peaton, entre otros.
- **Variables derivadas** (creadas en FASE 2): total_condiciones, es_grave, Gravedad_cod.

Tabla 1: Indicadores de calidad inicial del dataset

Indicador	Valor	Implicación
Total de registros	60 000	Tamaño suficiente para inferencia
Total de variables	27	5 dimensionales + 22 binarias
Duplicados exactos	44 017 (73.4 %)	Alto: sin identificador único
Nulos en <code>Elemento_Choque</code>	9 841 (16.4 %)	Imputación necesaria
Demás variables nulas	0	Dimensiones completas

¿Qué tan confiable es el dataset? La ausencia de nulos en las dimensiones principales sugiere captura sistemática. Sin embargo, el 73.4 % de duplicados exactos es una señal de alerta: sin un identificador único de evento no se puede determinar si dos filas idénticas son el mismo accidente registrado dos veces o accidentes distintos con características iguales.

¿Existen variables que inducen sesgo? Sí. `Con_Embriaguez` (2.18 % de «Sí») y `Con_Velocidad` (0.94 %) presentan frecuencias anómalamente bajas. Esto refleja sesgo de subregistro: la embriaguez se registra solo cuando hay prueba positiva en el lugar del accidente, no cada vez que ocurre. Interpretar «no hay asociación estadística entre embriaguez y gravedad» como «la embriaguez no influye» sería un error metodológico grave.

6.2. Tratamiento de Nulos y Duplicados

Los 9 841 nulos de `Elemento_Choque` se imputaron con la categoría ‘Desconocido’, preservando la validez del evento. No imputar habría generado pérdida del 16.4 % de registros sin ningún beneficio analítico.

Respecto a los duplicados, la decisión fue **conservarlos**. Las razones son:

1. El dataset no tiene identificador único de evento; eliminar duplicados implica asumir que filas idénticas son errores de carga, lo cual no puede confirmarse.
2. Eliminar el 73.4 % de los registros eliminaría también patrones reales de accidentalidad en condiciones similares.
3. El impacto analítico de los duplicados es que inflan los conteos y las pruebas estadísticas (cualquier diferencia se vuelve significativa con $n = 60\,000$), lo que obliga a complementar el p -valor con tamaños de efecto.

Implicación ética: Presentar estadísticas de accidentalidad basadas en este dataset sin advertir la duplicación podría inducir a sobreestimar la frecuencia de siniestros y a diseñar políticas con recursos mal asignados.

6.3. Estandarización y Variables Derivadas

- `Dia_Semana_Acc`: homogeneización con `capitalize()`.
- Variables categóricas convertidas a tipo `category`.
- Variables `Con_*` codificadas 1/0 para cálculos numéricos.
- `total_condiciones`: suma de los 22 indicadores `Con_*` activos por registro. Funciona como proxy de la complejidad del accidente.

- `es_grave`: binario (1 si gravedad $\neq$ «Solo Daños»).
- `Gravedad_cod`: ordinal (0 = Solo Daños, 1 = Con Heridos, 2 = Con Muertos).

7. Estadística Descriptiva

7.1. Distribuciones de Frecuencia

La Figura ?? resume los patrones globales del dataset. El panel superior izquierdo revela que el 57.2 % de los siniestros son de «Solo Daños», el 41.4 % generan heridos y apenas el 1.4 % son fatales. Esta distribución asimétrica hacia los eventos menos graves es característica de los sistemas de registro administrativo: los accidentes leves se registran con mayor sistematicidad que los graves, que suelen involucrar múltiples entidades.

El panel superior derecho muestra que el choque es la clase de accidente dominante (83.4 % del total), seguido por atropello (11.7 %). Esta proporción es relevante para priorizar intervenciones: los atropellos, aunque menos frecuentes, involucran usuarios vulnerables y tienen mayor proporción de heridos graves.

El panel inferior izquierdo evidencia una distribución relativamente uniforme por día de semana de lunes a sábado ($\approx 14\text{--}16\%$ cada día), con caída notable el domingo ($\approx 10,5\%$). Esto sugiere que la accidentalidad está asociada a la actividad laboral y de movilidad cotidiana, no a eventos especiales de fin de semana.

El panel inferior derecho ubica a Kennedy como la localidad con mayor carga de siniestros ($> 7\,000$ registros), seguida por Engativá y Usaquén. Esta concentración puede reflejar tanto mayor densidad vehicular como menor infraestructura de control vial en estas zonas.




Figura 1: Distribuciones de frecuencia: gravedad del accidente, clase de accidente, proporción por día de semana y top 10 localidades. La asimetría en gravedad y la dominancia del choque condicionan todos los análisis posteriores.

7.2. Histogramas: Total de Condiciones Activas

La Figura ?? muestra que la variable `total_condiciones` sigue una distribución discreta sesgada a la derecha: el valor más frecuente es 1 condición activa ($\approx 18\,500$ registros), seguido de 2 y 3. El panel derecho confirma que `Con_Moto` es la condición más registrada ($\approx 18\,000$ registros), lo que convierte a la motocicleta en el actor vial con mayor presencia relativa en los siniestros.

¿Qué implica este patrón? La mayoría de los accidentes se registran con pocas condiciones activas. Esto puede reflejar tanto la realidad (accidentes simples dominan estadísticamente) como el subregistro: los formularios de captura solo recogen las condiciones más visibles. Un accidente puede tener velocidad excesiva, embriaguez y estado de la vía deteriorado, pero solo se registran las más obvias o las que el agente de tránsito puede verificar en el momento.




Figura 2: Histograma del número de condiciones activas por accidente (izq.) y frecuencia absoluta de cada condición **Con_*** (der.). **Con_Moto** domina claramente, señal de la alta exposición de motociclistas en el sistema vial.

7.3. Boxplots: Condiciones por Gravedad y Clase

La Figura ?? muestra que la mediana de `total_condiciones` es prácticamente la misma (2) entre los tres niveles de gravedad. Sin embargo, los accidentes «Con Muertos» presentan una distribución ligeramente más compacta (menor dispersión), lo que podría indicar que los accidentes fatales ocurren con patrones de condiciones más específicos. En el panel derecho, los atropellos presentan la mediana más alta entre todas las clases de accidente, coherente con la complejidad inherente de los eventos con peatones.

¿Qué riesgo social evidencia este patrón? La similitud de medianas entre «Solo Daños» y «Con Muertos» indica que el número de condiciones activas *por sí solo* no es un buen predictor de la gravedad. Esto sugiere que la *combinación específica* de condiciones (cuáles están activas, no cuántas) es lo que determina la severidad del resultado.




Figura 3: Boxplots de `total_condiciones` por nivel de gravedad (izq.) y clase de accidente (der.). La similitud de medianas entre niveles de gravedad indica que el conteo de condiciones no discrimina por sí solo la severidad del evento.

7.4. Histogramas Obligatorios: Variables Clave

La Figura ?? presenta los histogramas de las variables más relevantes para el modelado. `total condiciones` muestra distribución discreta y asimétrica. Con `Velocidad` y `Con Huecos`

tienen casi la totalidad de sus registros en 0 (subregistro extremo: $< 1\%$ de ocurrencia), lo cual las hace prácticamente inútiles para modelado sin corrección por sesgo. **Gravedad_cod** muestra tres picos discretos en 0, 1 y 2, siendo el valor 0 el más frecuente.




Figura 4: Histogramas de **total_condiciones**, **Con_Velocidad**, **Con_Huecos** y **Gravedad_cod**. El subregistro extremo en **Con_Velocidad** y **Con_Huecos** limita su uso como predictores confiables.

7.5. Boxplots Obligatorios: Gravedad por Dimensiones

La Figura ?? presenta boxplots de gravedad segmentada por las principales dimensiones. En el panel de localidades, la mediana es 1 en todas las localidades analizadas, pero la dispersión varía: algunas localidades periféricas (Usme, Tunjuelito) muestran colas superiores más cortas, lo que podría reflejar menor registro de accidentes graves o menor exposición. En el panel por día de semana, no hay diferencias marcadas en mediana, aunque el viernes muestra el bigote superior más amplio. Los boxplots de **Con_Moto** y **Con_Peaton** revelan algo importante: cuando hay moto o peatón involucrado, el boxplot se comprime hacia el valor 1, indicando menor variabilidad pero mayor concentración en el nivel «Con Heridos».




Figura 5: Boxplots de `Gravedad_cod` por localidad, día de semana, `Con_Moto`, `Con_Embriaguez` y `Con_Peaton`. La compresión del boxplot hacia el valor 1 cuando hay moto o peatón indica concentración en accidentes con heridos.

7.6. Medidas de Tendencia Central y Dispersión

Tabla 2: Estadísticas descriptivas principales

Variable	Media	Mediana	Desv. Std	Mín.	Máx.
<code>total_condiciones</code>	1.886	2.000	≈ 1.30	0	8
<code>Gravedad_cod</code>	0.429	0.000	≈ 0.59	0	2
<code>es_grave</code>	0.429	0.000	≈ 0.49	0	1
<code>Con_Moto</code>	0.302	0.000	≈ 0.46	0	1
<code>Con_Peaton</code>	0.130	0.000	≈ 0.34	0	1

7.7. Correlaciones

La Figura ?? presenta la matriz de correlación completa. Se destacan: correlación positiva entre `Con_Moto` y `es_grave` ($r \approx 0,30$); correlación positiva entre `Con_Peaton` y `es_grave` ($r \approx 0,25$); y correlaciones positivas entre variables de transporte público (`Con_Tpi`, `Con_Tpp`, `Con_Sitp`), esperables porque tienden a co-ocurrir. La correlación entre `total_condiciones` y `es_grave` ($r \approx 0,22$) confirma que más condiciones activas están asociadas a mayor severidad, aunque la relación es moderada.

¿Qué decisiones pueden tomarse? Los indicadores más correlacionados con la gravedad son candidatos prioritarios para campañas de prevención vial. Sin embargo, debe evitarse la falacia de confundir correlación con causalidad: que «presencia de moto» correlacione con gravedad no implica que «las motos causan accidentes graves», sino que los accidentes que involucran motos tienden a reportarse con mayor severidad.




Figura 6: Matriz de correlación (Pearson) entre variables indicadoras Con_*, variables derivadas y objetivos. Las correlaciones más altas con **es_grave** corresponden a **Con_Moto** y **Con_Peaton**.

8. KPI's y Previsión

Los KPI's (Key Performance Indicators) transforman los datos crudos en métricas interpretables para la toma de decisiones operativas. Se diseñaron los siguientes diez indicadores clave:

Tabla 3: KPI's diseñados para el análisis de accidentalidad

KPI	Fórmula	Interpretación estratégica
% Accidentes con heridos	$\frac{n_{\text{heridos}}}{N} \times 100$	41.4 %: base para alertas tempranas
% Accidentes graves (es_grave)	$\frac{n_{\text{grave}}}{N} \times 100$	42.88 % incluye heridos y muertos
Tasa accidentes con moto	$\frac{n_{\text{Con_Moto}=1}}{N} \times 100$	30.2 %: motos en 3 de cada 10 siniestros
% Accidentes con peatón	$\frac{n_{\text{Con_Peaton}=1}}{N} \times 100$	13.0 %: alto costo humano potencial
% Accidentes con embriaguez	$\frac{n_{\text{Con_Emb}=1}}{N} \times 100$	2.18 %: subregistro severo
Índice Kennedy	$\frac{n_{\text{Kennedy}}}{N} \times 100$	12.2 %: concentración en una localidad
Proporción viernes	$\frac{n_{\text{Viernes}}}{N} \times 100$	15.9 %: día de mayor siniestralidad
Promedio condiciones/accidente	$\frac{\sum \text{total_condiciones}}{N}$	1.886: baja complejidad promedio
% Choque como clase	$\frac{n_{\text{Choque}}}{N} \times 100$	83.4 %: clase dominante
% Siniestros domingo	$\frac{n_{\text{Domingo}}}{N} \times 100$	10.5 %: menor accidentalidad semanal

8.1. Visualización de KPI's

La Figura ?? sintetiza tres KPI's clave. El gráfico de barras por día de semana confirma que viernes y martes son los días de mayor accidentalidad proporcional, mientras el domingo desciende casi 5 puntos porcentuales respecto al viernes. El gráfico central muestra la asimetría entre factores de riesgo: **Con_Moto** está presente en el 30.2 % de los accidentes, mientras **Con_Embriaguez** apenas llega al 2.18 %, diferencia que no refleja la magnitud real de la embriaguez al volante. El gráfico de localidades confirma la concentración: las cinco primeras localidades concentran > 40 % del total de siniestros.




Figura 7: KPI's visualizados: proporción de accidentes por día de semana (izq.), factores de riesgo principales expresados como porcentaje (centro) y top localidades por número de accidentes (der.).

8.2. KPI: Distribución de Complejidad de Accidentes

La Figura ?? muestra el histograma con curva de densidad (*KDE*) de **total_condiciones**. Los picos multimodales a 1, 2 y 3 condiciones indican que los accidentes siguen patrones discretos de complejidad. El pico más alto en 1 condición sugiere que la mayoría de los eventos

registrados son «simples» en términos de factores concurrentes. La cola hacia 5–8 condiciones representa siniestros de alta complejidad con múltiples factores activos simultáneamente.




Figura 8: KPI de complejidad: distribución de `total_condiciones` con curva KDE. Los picos discretos reflejan la estructura binaria de los indicadores `Con_*`: la suma de ceros y unos genera una distribución multimodal característica.

8.3. KPI: Relación χ^2 vs Cramér's V

La Figura ?? muestra la fuerza de asociación (Cramér's V) y el estadístico χ^2 para los cinco indicadores con mayor asociación a la severidad. `Con_Moto` lidera en χ^2 ($= 14\,045$) y en V ($= 0,484$). Este resultado indica que la presencia de motocicleta es el factor individual con mayor relación estadística con la gravedad del accidente.

¿Puede un KPI ser engañoso? Sí. Presentar solo el χ^2 sin el V de Cramér sería engañoso: con 60 000 registros, cualquier diferencia marginal produce un χ^2 enorme. El V de Cramér normaliza el estadístico por el tamaño muestral y los grados de libertad, permitiendo comparaciones honestas entre variables.




Figura 9: Fuerza de asociación (Cramér's V) y estadístico χ^2 por indicador `Con_*`. La separación entre `Con_Moto/Con_Peaton` y el resto es marcada, confirmando su preponderancia analítica.

La Figura ?? muestra la relación bidimensional entre χ^2 y V: los indicadores con mayor efecto práctico (`Con_Moto`, `Con_Peaton`) se ubican en el cuadrante superior derecho, mientras

Con_Embriaguez queda relegado al origen, evidenciando su baja capacidad discriminativa por subregistro.




Figura 10: Dispersión χ^2 vs. Cramér's V . La posición de **Con_Embriaguez** en el origen no significa que la embriaguez no influya en la severidad; refleja el subregistro sistemático de este factor.

9. Pruebas de Normalidad

9.1. Importancia de la Normalidad

La normalidad es un supuesto de las pruebas paramétricas (prueba t de Student, ANOVA clásico, regresión con intervalos de confianza exactos). Si las variables no siguen una distribución normal, estas pruebas pueden producir inferencias inválidas. La importancia práctica de verificar la normalidad es decidir si se usan métodos paramétricos o sus equivalentes no paramétricos (Mann-Whitney U, Kruskal-Wallis).

Con $n = 60\,000$, el *Teorema del Límite Central* (TLC) garantiza que las medias muestrales se distribuyen aproximadamente normal independientemente de la distribución original. Sin embargo, el TLC **no implica** que las variables individuales sean normales, ni que los residuos de un modelo lineal sean normales con respuesta ordinal discreta.

9.2. Resultados: Con_Bicicleta

La Figura ?? muestra el histograma y QQ-plot de **Con_Bicicleta**. La distribución es binaria: el 92 % de los registros tiene valor 0. El QQ-plot muestra dos plataformas horizontales, completamente alejadas de la línea diagonal teórica. El test de Shapiro-Wilk (aplicado sobre muestra) rechaza normalidad con $p \approx 0$.




Figura 11: Histograma y QQ-plot de **Con_Bicicleta** ($n = 60\,000$, media = 0.08). La distribución binaria es incompatible con la normalidad; el QQ-plot lo confirma con sus dos plataformas características.

9.3. Resultados: Variables Adicionales

Las Figuras ??-?? muestran el mismo patrón para todas las variables **Con_***: distribuciones bimodales en 0 y 1, QQ-plots con plataformas horizontales y rechazos sistemáticos de normalidad. La Figura ?? presenta el caso de **Con_Moto**: media = 0.302, pico bimodal claro. Todas las variables **Con_*** son binarias y por definición no pueden ser normales.




Figura 12: Histograma y QQ-plot de **Con_Moto** (media = 0.302). Las dos masas en 0 y 1 confirman la naturaleza binaria. Shapiro-Wilk: $p \approx 10^{-58}$ en muestra.




Figura 13: Verificación de normalidad — segunda variable **Con_***: patrón binario idéntico, rechazo de normalidad.




Figura 14: Verificación de normalidad — tercera variable.




Figura 15: Verificación de normalidad — cuarta variable.




Figura 16: Verificación de normalidad — quinta variable.




Figura 17: Verificación de normalidad — séptima variable `Con_*`. El patrón se repite en todas las variables binarias del dataset.

9.4. Consecuencias Metodológicas

1. Todas las pruebas de comparación de grupos deben usar métodos **no paramétricos** (Mann-Whitney U, Kruskal-Wallis) como prueba principal.
2. Las pruebas t de Welch se aplican como referencia comparativa dado que con $n > 30\,000$ por grupo el TLC estabiliza el error.
3. Para regresión lineal, la no normalidad de los *predictores* no viola supuestos; importa la normalidad de los *residuos*.
4. Con $n = 60\,000$, cualquier diferencia trivial produce rechazo de normalidad en pruebas formales (Shapiro-Wilk es hipersensible). Por eso se usan histogramas y QQ-plots como diagnóstico complementario.

¿La normalidad es una propiedad real o una simplificación? Es principalmente una simplificación matemática útil. Pocas variables reales siguen exactamente una distribución normal; la normalidad se aproxima bajo ciertas condiciones. En fenómenos de seguridad vial, las distribuciones son inherentemente discretas, sesgadas y a menudo multimodales. La estadística robusta y no paramétrica es más apropiada para este tipo de datos.

Implicaciones reales: No significa que las motos *causen* la gravedad. Puede reflejar que los accidentes con motos tienen mayor probabilidad de registrarse como graves por la vulnerabilidad física del motociclista, que los protocolos de atención priorizan estos casos, o que la exposición al riesgo de las motos en el tráfico urbano es estructuralmente diferente a la de los automóviles.

10.3. Resultados: Hipótesis 2 — Peatón




Figura 19: Distribución de **Severidad_cod** según presencia de peatón. La diferencia entre los grupos es aún más marcada que en el caso de la motocicleta: el grupo «Con Peatón» tiene la caja centrada en 1 (Con Heridos) sin rango inferior.

$\chi^2 \approx 10680$, $p \approx 0$, Cramér's $V \approx 0,43$. Se rechaza H_0 . La interpretación es directa: los atropellos son inherentemente más graves porque el peatón carece de protección física. Una política de seguridad vial orientada a reducir la gravedad de los siniestros debe priorizar la protección del peatón.

10.4. Resultados: Hipótesis 3 — Embriaguez




Figura 20: Distribución de **Severidad_cod** según presencia de embriaguez. Los boxplots son prácticamente idénticos entre grupos, lo que, combinado con el subregistro severo (2.18 % de «Sí»), hace que la prueba no detecte diferencia significativa.

$\chi^2 \approx 0$, $p = 0,177$ (Mann-Whitney), Cramér's $V \approx 0,002$. No se rechaza H_0 .

Interpretación crítica: Este resultado *no significa* que la embriaguez no influya en la gravedad de los accidentes. Significa que el *registro de embriaguez* no se asocia estadísticamente con la gravedad en este dataset. La causa más probable es el sesgo de subregistro: la embriaguez solo se registra cuando hay prueba positiva documentada. Un análisis que concluya «la embriaguez no es factor de riesgo» basándose en este resultado sería una interpretación estadística engañosa. Sería necesario comparar con registros de alcoholemia obligatoria para obtener conclusiones válidas.

10.5. Resultados: Hipótesis 4 — Total de Condiciones



Figura 21: `total_condiciones` por accidente grave vs. no grave. Ambas distribuciones son similares en mediana ($= 2$) pero el grupo grave presenta cola superior ligeramente más pronunciada.

Kruskal-Wallis: $H = 3880$, $p \approx 0$. Se rechaza H_0 . Sin embargo, la diferencia práctica es pequeña: ambas medianas son 2. Esto confirma que el conteo de condiciones activas es un predictor débil de la gravedad por sí solo.

10.6. Ranking de Asociación: Todos los Indicadores

La Figura ?? muestra el ranking completo de los 19 indicadores `Con_*` con asociación significativa, ordenados por Cramér's V , y el diagrama de dispersión p -valor vs. tamaño de efecto. Se observa claramente una separación entre `Con_Moto` y `Con_Peaton` (efectos medianos-grandes) y el resto de indicadores (efectos pequeños). `Con_Sitp` tiene el valor V más bajo y p -valor más grande, sugiriendo que la presencia de SITP tiene escasa asociación con la gravedad.




Figura 22: Ranking de indicadores `Con_*` por Cramér's V (izq.) y dispersión p -valor vs. efecto (der.). La brecha entre `Con_Moto/Con_Peaton` y el resto delimita los factores con relevancia práctica real.

Errores tipo I y II: Con $n = 60\,000$, el riesgo principal es el error tipo I de interpretación (no estadístico): rechazar H_0 y concluir «efecto relevante» cuando $V < 0,1$ indica efecto trivial. El error tipo II (falso negativo) es casi nulo dado el enorme poder estadístico de la muestra.

11. Pruebas t

11.1. Objetivo

La prueba t compara si la media de una variable cuantitativa difiere significativamente entre dos grupos. Se aplica para comparar la severidad (o el número de condiciones) entre accidentes con y sin motocicleta, controlando por varianzas posiblemente distintas (prueba de Welch).

11.2. Validación de Supuestos

- **Normalidad:** Rechazada para `total_condiciones` y `Con_Moto` (Shapiro-Wilk $p \approx 10^{-58}$). Con grupos de $n > 18\,000$ el TLC mitiga el problema; sin embargo, se complementa con Mann-Whitney.
- **Homocedasticidad:** Levene $p \approx 0$, varianzas desiguales. Se usa la corrección de Welch.

- **Independencia:** Asumida; no hay dependencia temporal declarada en el dataset.

11.3. Resultados

Tabla 4: Prueba t de Welch: comparación por presencia de motocicleta

Estadístico	Con Moto	Sin Moto	Resultado
n	18 089	41 911	
Media <code>total_condiciones</code>	$\approx 2,1$	$\approx 1,8$	
Prueba t Welch	$t = 131,9, p \approx 0$		Se rechaza H_0

La Figura ?? combina boxplot y violín para mostrar la distribución completa. La forma de violín revela que ambos grupos tienen distribuciones similares en estructura (multimodales, discretas), pero el grupo «Con Moto» tiene una concentración levemente mayor en valores intermedios.




Figura 23: Boxplot y violín de `total_condiciones` por presencia de motocicleta. La forma multimodal discreta confirma que la prueba t es aproximada; la similitud de medianas ($= 2$ en ambos grupos) indica que la diferencia de medias es pequeña en términos prácticos.

11.4. Interpretación Crítica

¿Una diferencia estadística implica causalidad? No. Que los accidentes con motocicleta tengan en promedio 0.3 condiciones más activas que los sin motocicleta es estadísticamente significativo pero no causalmente informativo. Puede reflejar que los siniestros con motos ocurren en entornos de mayor riesgo (vías con más factores de exposición), que se documentan más condiciones cuando hay usuarios vulnerables, o que la combinación moto + otros factores es lo que explica la diferencia.

¿Existen variables ocultas? Sí. Hora del día, tipo de vía, condiciones del pavimento, velocidad máxima permitida y experiencia del conductor son variables no disponibles en el dataset que pueden estar correlacionadas tanto con la presencia de motocicleta como con la gravedad, generando confusión.

12. Wilcoxon y Mann-Whitney

12.1. ¿Cuándo usar pruebas no paramétricas?

Las pruebas no paramétricas no asumen distribución específica de los datos. Son preferibles cuando:

- La distribución es claramente no normal (como en todos los indicadores `Con_*`).
- Las muestras son pequeñas y la normalidad no puede asumirse.
- La variable es ordinal o discreta con pocos valores posibles.
- Existen outliers severos que distorsionan la media.

En este análisis, dado que *todas* las variables son binarias o discretas y rechazan normalidad, Mann-Whitney U es la prueba principal para comparar grupos de dos categorías.

12.2. Aplicación: `Con_Moto` y `Con_Peaton`

Tabla 5: Pruebas Mann-Whitney U para los principales factores

Factor	n_1	n_2	U	p -valor
<code>Con_Moto</code> (1 vs 0)	18 089	41 911	415 165 043	$5,98 \times 10^{-81}$
<code>Con_Peaton</code> (1 vs 0)	7 782	52 218	significativo	≈ 0
<code>Con_Embriaguez</code> (1 vs 0)	1 309	58 691	39 135 399	0,177

El rango biserial para `Con_Moto` es $r = -0,095$, tamaño de efecto pequeño. La Figura ?? muestra el análisis de `Con_Peaton`: los accidentes con peatón tienen distribución de `total_condiciones` desplazada hacia valores más altos. El violín del grupo «Con Peatón» es más compacto y elevado, confirmando mayor concentración de condiciones activas en atropellos.




Figura 24: Boxplot y violín de `total_condiciones` por presencia de peatón. El grupo «Con Peatón» muestra mayor número de condiciones activas en la cola superior, coherente con la complejidad de los atropellos como eventos multifactoriales.

12.3. Diferencias entre Enfoque Paramétrico y No Paramétrico

- La prueba t compara medias y es sensible a outliers. Con n grande, cualquier diferencia de media produce t grande y $p \approx 0$.
- Mann-Whitney compara rangos y es robusta a outliers y distribuciones no simétricas. El rango biserial (r) es comparable al d de Cohen para tamaños de efecto.
- En este dataset, ambas pruebas producen los mismos resultados cualitativos dado el tamaño muestral, pero el rango biserial $r = -0,095$ para `Con_Moto` comunica mejor que el efecto es pequeño en términos prácticos, aunque estadísticamente robusto.

¿Cuándo una prueba robusta es preferible? Siempre que las distribuciones sean asimétricas, los datos sean ordinales o existan outliers influyentes. En analítica de seguridad vial, donde los eventos extremos (accidentes fatales) son los de mayor interés pero los menos frecuentes, los métodos robustos capturan mejor la realidad de los datos.

13. ANOVA

13.1. Objetivo y Formulación

Se aplica ANOVA de un factor para evaluar si la media de `Gravedad_cod` difiere significativamente entre las distintas localidades del dataset. La hipótesis es:

$$H_0 : \mu_{\text{Kennedy}} = \mu_{\text{Engativá}} = \dots = \mu_{\text{Sumapaz}}$$

$$H_1 : \text{Al menos una media de localidad es diferente.}$$

13.2. Resultados

$$F = 195,463, \quad p = 1,164 \times 10^{-165}$$

Se rechaza H_0 con altísima confianza. Existen diferencias significativas en la media de gravedad codificada entre localidades.

La Figura ?? muestra la distribución y medias para las cinco localidades más grandes. Kennedy presenta la media más alta ($\approx 0,52$), mientras Usaquén tiene la más baja ($\approx 0,30$). La diferencia entre Kennedy y Usaquén puede interpretarse como que, en Kennedy, un accidente promedio es más grave que en Usaquén.




Figura 25: Distribución de **Gravedad_cod** por localidad (top 5): boxplot (izq.) y media por localidad (der.). $F = 195,5$, $p \approx 10^{-165}$. Kennedy muestra la mayor severidad media, Usaquén la menor.

La Figura ?? muestra el panorama completo de todas las localidades ordenadas por mediana de severidad. La mediana es 1 en casi todas (indicando predominio de «Con Heridos»), pero las diferencias en los bigotes y outliers revelan distintos perfiles de riesgo territorial.




Figura 26: Severidad por localidad (todas), ordenadas por mediana. La mediana uniforme de 1 en la mayoría contrasta con la variabilidad en la cola superior, que diferencia las localidades con mayor proporción de accidentes fatales.

13.3. Interpretación Crítica

¿Por qué ciertos territorios presentan mayor severidad? Las posibles explicaciones son múltiples y no mutuamente excluyentes:

- **Densidad vehicular y tipo de vías:** Localidades industriales o de alta circulación (Kennedy, Fontibón) concentran más vehículos pesados, que generan accidentes más graves.
- **Infraestructura vial:** Localidades con mayor proporción de vías sin separador, intersecciones sin semáforo o señalización deficiente pueden tener mayor riesgo inherente.

- **Desigualdad urbana:** Las localidades periféricas (Usme, Ciudad Bolívar) pueden tener menos registro formal de accidentes, no necesariamente menor accidentalidad real. El ANOVA mide diferencias en lo registrado, no en la realidad completa.
- **Presencia de motos:** Si algunas localidades tienen mayor proporción de motociclistas (por ser zonas de entrega o de menor acceso al transporte público), la mayor severidad puede ser un efecto de composición, no de la localidad per se.

¿Los datos reflejan desigualdad urbana? Parcialmente. La mayor severidad en Kennedy respecto a Usaquén podría reflejar tanto diferencias reales en la peligrosidad de las vías como diferencias en la densidad de usuarios vulnerables (motos, peatones) que caracterizan cada zona socioeconómica. Interpretar estos resultados sin este contexto sería una reducción estadística inaceptable para política pública.

14. Regresión Múltiple

14.1. Construcción del Modelo

Se construyó un modelo de regresión lineal múltiple con `Gravedad_cod` como variable dependiente (codificación ordinal: 0, 1, 2) y los indicadores `Con_*` más variables categóricas codificadas como predictores. El pipeline incluye `OrdinalEncoder` para variables categóricas y validación cruzada estratificada de 5 pliegues.

Selección de variables independientes: Se incluyeron todas las variables `Con_*` más `Clase_Acc`, `Localidad` y `Elemento_Choque`. Las variables con subregistro severo (`Con_Velocidad`, `Con_Huecos`) se incluyeron para que el modelo evaluara su aporte, esperando coeficientes cercanos a cero.

14.2. Métricas de Desempeño

Tabla 6: Desempeño del modelo de regresión lineal múltiple

Métrica	Valor
R^2 en conjunto de test	0.400
MSE en conjunto de test	0.169
CV R^2 (5-fold, media)	0.398
Rango CV R^2	[0.389, 0.406]
RMSE	≈ 0.411

El modelo explica el **40 %** de la varianza de la gravedad. La consistencia entre test y validación cruzada ($R^2 = 0,400$ vs. 0,398) indica **ausencia de sobreajuste**. La diferencia mínima entre pliegues ([0.389, 0.406]) confirma estabilidad.

14.3. Análisis de Residuos

La Figura ?? muestra los valores reales vs. predichos. Los puntos azules (reales: 0, 1, 2) contrastan con los predichos continuos (naranja). El modelo predice valores intermedios entre

las categorías discretas, lo cual es una limitación inherente de la regresión lineal sobre una variable ordinal.




Figura 27: Valores reales (azul: 0, 1, 2) vs. predichos (naranja: continuos) de la regresión lineal. Los predichos se distribuyen entre las categorías reales, mostrando la limitación del modelo lineal para respuestas ordinales discretas.

La Figura ?? presenta el gráfico de residuos vs. predichos (izq.) y el QQ-plot de residuos (der.). Las franjas diagonales son consecuencia directa de la naturaleza discreta de la variable respuesta: para predichos cercanos a 0.5, el residuo puede ser $+0,5$ (si el real es 1) o $-0,5$ (si el real es 0), formando líneas paralelas. El QQ-plot muestra colas pesadas respecto a la normal teórica, esperables con respuesta ordinal.




Figura 28: Diagnóstico de residuos: residuos vs. predichos (izq.) y QQ-plot (der.). Las franjas diagonales son el patrón esperado cuando se aplica regresión lineal a una respuesta ordinal con tres niveles. No indican un fallo del modelo sino su limitación estructural.




Figura 29: Residuos vs. predichos de la regresión lineal. Las tres bandas de residuos corresponden a los tres valores posibles de `Gravedad_cod`. La dispersión uniforme dentro de cada banda indica que no hay heteroscedasticidad severa.

14.4. Interpretación Crítica

¿Qué variables realmente aportan? Las variables `Con_Moto`, `Con_Peaton` y `Con_Bicicleta` tienen los coeficientes positivos más altos, coherente con los resultados de las pruebas de hipótesis. `Con_Embriaguez` y `Con_Velocidad` tienen coeficientes cercanos a cero, confirmando que el subregistro los hace informativamente inútiles para el modelo.

¿El modelo explica causalidad o asociación? Solo asociación. Un $R^2 = 0,40$ significa que el 40 % de la varianza de la gravedad puede explicarse con las variables incluidas; el 60 % restante queda fuera del modelo. Las variables omitidas (velocidad real, condición de la vía, hora exacta) probablemente explican una parte importante de esa varianza no capturada.

¿Sobreajuste? No. La estabilidad en validación cruzada descarta sobreajuste.

¿Multicolinealidad? Las variables de transporte público (`Con_Tpi`, `Con_Tpp`, `Con_Sitp`) están correlacionadas entre sí, lo que puede inflar la varianza de sus coeficientes individuales. Se recomienda aplicar regularización (Ridge/Lasso) en iteraciones futuras.

¿Utilidad real del modelo? Limitada pero presente. El modelo puede usarse para priorizar casos con mayor probabilidad de gravedad, pero no para tomar decisiones individuales de alto impacto (como triaje médico), donde las consecuencias de un falso negativo son graves.

15. Regresión Logística

15.1. Construcción del Modelo

Se entrenó un clasificador logístico binario para predecir `es_grave` (1 = grave, 0 = no grave). La muestra de entrenamiento es de 60 000 registros. Para la evaluación con datos balanceados

se separó un 25 % para test con estratificación por clase.

Variable dependiente: `es_grave` (binaria: 1 si Con Heridos o Con Muertos, 0 si Solo Daños).

Variables independientes: Los mismos predictores que en la regresión múltiple.

15.2. Coeficientes del Modelo

La Figura ?? muestra los 15 coeficientes con mayor magnitud. `Con_Peaton` es el predictor positivo más influyente (coeficiente $\approx 3,0$), seguido de `Con_Moto` ($\approx 1,25$) y `Con_Bicicleta` ($\approx 1,0$). El coeficiente de `Elemento_Choque_cod` es negativo ($\approx -0,8$), indicando que ciertos tipos de elemento de choque están asociados a menor probabilidad de accidente grave.




Figura 30: Top 15 coeficientes del clasificador logístico. Los valores positivos aumentan la probabilidad de clasificar un siniestro como grave. `Con_Peaton` es el predictor de mayor peso, con coeficiente $\approx 3,0$ en escala log-odds.

Interpretación: Un coeficiente de 3.0 para `Con_Peaton` en log-odds equivale a un *odds ratio* de $e^3 \approx 20$: la probabilidad de ser clasificado como grave es 20 veces mayor cuando hay un peatón involucrado, manteniendo todo lo demás constante. Este resultado es consistente con los análisis previos y con la realidad física: el peatón es el usuario más vulnerable del sistema vial.

15.3. Curva ROC

La Figura ?? muestra la curva ROC del clasificador con $AUC = 0.93$.




Figura 31: Curva ROC del clasificador logístico. $AUC = 0.93$ indica alta capacidad discriminativa: el modelo puede ordenar correctamente los casos de mayor riesgo en el 93 % de las comparaciones aleatorias entre un caso grave y uno no grave.

El AUC-ROC de 0.93 significa que si se toman al azar un accidente grave y uno no grave, el modelo asignará mayor probabilidad al grave en el 93 % de los casos. Esto es un indicador de discriminación, independiente del umbral de clasificación.

15.4. Matriz de Confusión — Escenario Balanceado

La Figura ?? muestra la matriz de confusión sobre un conjunto de test con las clases relativamente balanceadas. Resultados: 6 004 verdaderos negativos (TN), 4 622 verdaderos positivos (TP), 524 falsos negativos (FN) y 850 falsos positivos (FP).




Figura 32: Matriz de confusión con clases balanceadas: 6 004 TN, 4 622 TP, 850 FP, 524 FN. El recall de la clase grave es $4622/(4622 + 524) \approx 0,90$: el modelo detecta el 90 % de los accidentes realmente graves.

Tabla 7: Métricas de clasificación — escenario balanceado

Clase	Precisión	Recall	F1-score	Soporte
0 (no grave)	0.92	0.88	0.90	6 854
1 (grave)	0.84	0.90	0.87	5 146
AUC-ROC	0.926 856			

15.5. Matriz de Confusión — Escenario con Desbalance Extremo

La Figura ?? muestra el resultado del clasificador cuando el conjunto de test tiene desbalance extremo (clase grave = 1.8 % del total). Resultado: 14 721 TN, 6 FP, 273 FN, 0 TP. El modelo clasifica todo como «no grave».




Figura 33: Matriz de confusión con desbalance extremo (clase grave = 1.8 %). El modelo clasifica todo como «no grave» (0 TP). La accuracy en este escenario es 98.1 % pero el recall de la clase grave es 0 %. Esta es la *paradoja del desbalance*.

La paradoja del desbalance: Con 14 721 negativos y 273 positivos, un clasificador que prediga siempre 0 tiene $\text{accuracy} = 14\,727/15\,000 = 98,1\%$. Esto ilustra por qué la accuracy no es una métrica adecuada cuando las clases están desbalanceadas.

15.6. Interpretación Crítica

¿Qué tan confiable es el modelo? Muy confiable para discriminación global ($\text{AUC} = 0.93$) pero su confiabilidad operativa depende del umbral y del balanceo de clases. En el escenario balanceado (Figura ??), el recall de la clase grave es del 90 %, lo cual es útil. En el escenario desbalanceado, falla completamente.

¿Qué consecuencias tendría un falso negativo? En el contexto de seguridad vial, un falso negativo significa clasificar como «no grave» un accidente que sí lo es. Las consecuencias pueden incluir: no despachar recursos de emergencia suficientes, no activar protocolos de

intervención territorial, no alertar a los servicios de salud. En sistemas de triage o priorización de atención, el coste de un falso negativo es inaceptablemente alto.

¿Podría existir discriminación algorítmica? Sí. Si el modelo aprende que ciertos territorios (localidades) o ciertos tipos de vehículo predicen la gravedad, y estos correlacionan con condiciones socioeconómicas, el modelo podría reproducir sesgos estructurales existentes. Por ejemplo, si las localidades de mayor pobreza tienen mayor proporción de usuarios en moto y el modelo les asigna mayor riesgo, esto podría usarse para concentrar recursos de control en esas zonas, perpetuando la estigmatización territorial en lugar de abordar las causas estructurales.

¿Qué se recomienda para mejorar el modelo?

- Ajuste de umbral óptimo según coste de falsos negativos vs. falsos positivos.
- Técnicas de sobremuestreo (SMOTE) para la clase grave en el entrenamiento.
- Ponderación de clases con `class_weight='balanced'`.
- Explorar modelos no lineales (Random Forest, Gradient Boosting) que puedan capturar interacciones entre factores.

16. Discusión Crítica

16.1. Limitaciones del Dataset

1. **73.4 % de duplicados exactos:** Ninguna estimación de frecuencias absolutas es válida sin reconocer que los conteos están inflados. Eliminarlos tampoco es trivial por la ausencia de identificador único.
2. **Subregistro sistemático:** Variables como embriaguez y velocidad capturan menos del 3 % de ocurrencias, cuando la evidencia epidemiológica global sugiere tasas mucho mayores. Las conclusiones sobre estas variables reflejan el proceso de captura, no la realidad del fenómeno.
3. **Ausencia de variables contextuales:** No hay información sobre condiciones climáticas, estado del pavimento, flujo vehicular, hora exacta, experiencia del conductor ni infraestructura del tramo. Estas variables tienen potencial explicativo alto y su ausencia genera variables omitidas que sesgan los coeficientes estimados.

16.2. Posibles Sesgos

- **Sesgo de selección:** Solo se registran los accidentes reportados formalmente. Los accidentes menores que no generan reporte policial están ausentes.
- **Sesgo de medición:** La gravedad se determina al momento del reporte, no al del desenlace final. Un accidente inicialmente clasificado como «Solo Daños» puede derivar en heridos; esto no se actualiza en el registro.
- **Sesgo de confirmación:** El analista que codifica el accidente puede registrar más condiciones cuando el resultado es grave (atención selectiva), lo que inflaría artificialmente las asociaciones.

16.3. Diferencia entre Correlación y Causalidad

El análisis demuestra que `Con_Moto` está fuertemente asociado a la gravedad ($V = 0,484$). Esto **no** permite concluir que las motos *causan* accidentes graves. La correlación puede deberse a:

- Causalidad real: los accidentes con motos son inherentemente más peligrosos.
- Confusión: las motos circulan en condiciones de mayor riesgo (velocidades más altas, zonas con peor infraestructura).
- Sesgo de registro: los accidentes con motos se registran con más detalle cuando hay usuarios vulnerables involucrados.

Para establecer causalidad se requieren diseños cuasi-experimentales, series temporales o datos con variación exógena (por ejemplo, zonas con y sin restricción de motos antes y después de una intervención).

16.4. Implicaciones Sociales y Éticas

- **Uso responsable:** Los modelos predictivos en seguridad vial pueden ayudar a priorizar recursos, pero no deben reemplazar el juicio institucional ni usarse para criminalizar conductores de motos o peatones de ciertas zonas.
- **Transparencia:** Cualquier sistema de alerta basado en estos modelos debe documentar sus limitaciones, tasas de error y el impacto diferencial sobre grupos sociales.
- **Actualización:** Los modelos entrenan sobre datos históricos. Si los patrones de accidentalidad cambian (por intervenciones de infraestructura, cambios en el parque automotor), los modelos deben reentrenarse.

16.5. Rol de la Ingeniería de Sistemas

El ingeniero de sistemas en analítica de datos no es solo un programador que ejecuta algoritmos. Es un profesional que debe *cuestionar los datos, interpretar los resultados en su contexto y comunicar honestamente las limitaciones*. La capacidad de construir un modelo con $AUC = 0.93$ es técnicamente valiosa; la capacidad de explicar qué significa ese número, cuándo el modelo falla y qué decisiones no deben basarse en él, es lo que distingue al ingeniero analítico del operador de software.

17. Conclusiones

1. **La calidad del dato es el principal condicionante del análisis.** El 73.4 % de duplicados y el subregistro en variables clave (embriaguez, velocidad) limitan la validez de cualquier estimación de frecuencia absoluta. Toda conclusión debe estar acompañada de esta advertencia metodológica.
2. **Motocicleta y peatón son los factores de mayor peso estadístico.** `Con_Moto` ($V = 0,484$) y `Con_Peaton` ($V \approx 0,43$) presentan las asociaciones más fuertes y estables con la gravedad del siniestro, confirmadas por chi-cuadrado, Mann-Whitney, coeficientes del modelo logístico y análisis descriptivo. Políticas de seguridad vial orientadas a proteger estos usuarios tienen respaldo estadístico.

3. **El modelo logístico discrimina bien globalmente ($AUC = 0.93$) pero su utilidad operativa depende del umbral.** En escenario balanceado alcanza recall = 90 % para accidentes graves. En escenario desbalanceado, el modelo falla completamente en detectar la clase de interés, recordando que la accuracy no es la métrica adecuada cuando las clases están desbalanceadas.
4. **La variación territorial es estadísticamente significativa** (ANOVA $F = 195,5$, $p \approx 10^{-165}$), pero debe interpretarse con cautela: las diferencias de severidad entre localidades pueden reflejar tanto diferencias reales en la peligrosidad de las vías como diferencias en la composición del parque vehicular y en las condiciones socioeconómicas.
5. **La regresión lineal explica el 40 % de la varianza.** El 60 % restante corresponde a variables no disponibles en el dataset, lo que indica que un sistema predictivo robusto requeriría enriquecer los datos con variables contextuales.

18. Recomendaciones

1. **Mejorar el sistema de captura de datos:** implementar identificadores únicos de evento, registrar condiciones de embriaguez con prueba de alcoholemia obligatoria, incluir velocidad estimada y estado del pavimento.
2. **Aplicar balanceo de clases** en el entrenamiento de modelos predictivos (SMOTE, ponderación, umbral ajustado) para mejorar la detección de accidentes graves.
3. **Explorar modelos no lineales** (Random Forest, Gradient Boosting) que puedan capturar interacciones entre factores y reducir el sesgo de modelos lineales sobre datos ordinales.
4. **Integrar datos geoespaciales:** un modelo que incorpore tipo de vía, densidad vehicular y cobertura de semáforos por segmento vial tendría mayor capacidad predictiva y mayor utilidad para intervenciones de infraestructura.
5. **Validar el modelo con datos de otro periodo temporal:** entrenar con un año y predecir sobre otro para evaluar la estabilidad temporal de las asociaciones encontradas.
6. **Diseñar un panel de KPI's en tiempo real:** los indicadores diseñados (tasa de accidentes con moto, índice por localidad, proporción por día) son adecuados para un dashboard de monitoreo que apoye la toma de decisiones operativas de la autoridad de tránsito.

Referencias

Referencias

- [1] Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3–4), 591–611.
- [2] Mann, H. B., & Whitney, D. R. (1947). On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1), 50–60.
- [3] Kruskal, W. H., & Wallis, W. A. (1952). Use of ranks in one-criterion variance analysis. *Journal of the American Statistical Association*, 47(260), 583–621.

- [4] Cramér, H. (1946). *Mathematical Methods of Statistics*. Princeton University Press.
- [5] Pedregosa, F., Varoquaux, G., Gramfort, A., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [6] Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874.
- [7] Dataset de siniestros viales suministrado por el curso. Archivo: 02_04_crash_severity.csv.

A. Gráficos de Barras Obligatorios

Los siguientes gráficos de barras resumen la distribución de conteos por las principales dimensiones del dataset, cumpliendo el requisito de visualizaciones obligatorias.




Figura 34: Gráficos de barras de conteos por localidad (top 20), día de semana, Con_Moto, Con_Embriaguez y Con_Peaton. Estos paneles confirman la concentración territorial en Kennedy y la predominancia de viernes como día de mayor accidentalidad.

B. Resumen de Resultados Estadísticos

Tabla 8: Resumen global de todas las métricas del análisis

Indicador	Valor
Total registros	60 000
Total variables	27
Duplicados exactos	44 017 (73.4 %)
Media <code>total_condiciones</code>	1.886
Mediana <code>total_condiciones</code>	2.0
% accidentes graves (<code>es_grave</code>)	42.88 %
χ^2 <code>Con_Moto</code>	14 045.046
Cramér's V <code>Con_Moto</code>	0.484
χ^2 <code>Con_Peaton</code>	$\approx 10\,680$
Cramér's V <code>Con_Peaton</code>	≈ 0.43
ANOVA localidades F	195.463
p -valor ANOVA	$1,164 \times 10^{-165}$
Mann-Whitney r (<code>Con_Moto</code>)	-0,095
R^2 regresión lineal (test)	0.400
MSE regresión lineal (test)	0.169
CV R^2 media (5-fold)	0.398
AUC-ROC clasificador logístico	0.926 856
Recall clase grave (balanceado)	≈ 0.90
F1-score clase grave (balanceado)	0.87