

Trabajo Final de Curso
Analítica de Datos
Facultad de Ingeniería
Universidad Católica de Colombia

Título del proyecto

"Análisis Predictivo y Estadístico de la Severidad de Accidentes de Tránsito mediante Técnicas de Analítica de Datos y Python"

Introducción

La analítica de datos se ha convertido en uno de los pilares fundamentales de la Ingeniería de Sistemas moderna. En la actualidad, las organizaciones públicas y privadas toman decisiones estratégicas basadas en información cuantitativa obtenida a partir de grandes volúmenes de datos. Sin embargo, el verdadero valor de los datos no radica únicamente en almacenarlos o visualizarlos, sino en interpretarlos críticamente, comprender sus patrones y transformar los resultados en conocimiento útil para la toma de decisiones.

El presente trabajo final integra todos los temas desarrollados durante el curso: estadística descriptiva, captura y limpieza de datos, análisis exploratorio, KPI's, pruebas de hipótesis, pruebas paramétricas y no paramétricas, ANOVA, regresión múltiple y regresión logística. El objetivo es que el estudiante desarrolle una solución analítica completa utilizando Python como lenguaje principal de programación.

El dataset suministrado contiene información relacionada con accidentes de tránsito y variables asociadas a la severidad del accidente, presencia de motocicletas, bicicletas, peatones, embriaguez, huecos, taxis, transporte público, entre otros factores relevantes. Este conjunto de datos permitirá desarrollar análisis estadísticos reales y construir modelos predictivos enfocados en comprender qué variables influyen significativamente en la gravedad de los accidentes.

Más allá de ejecutar código o generar gráficos, este trabajo busca que el estudiante desarrolle pensamiento crítico analítico. Cada prueba estadística realizada deberá interpretarse desde una perspectiva técnica y social. No se evaluará únicamente la capacidad de programar, sino también la habilidad de argumentar decisiones, justificar modelos y cuestionar los resultados obtenidos.

Contexto del Problema

Las ciudades modernas enfrentan múltiples desafíos relacionados con la movilidad urbana y la seguridad vial. El aumento del parque automotor, el crecimiento demográfico y las deficiencias en infraestructura generan escenarios complejos donde los accidentes de tránsito representan una problemática social, económica y de salud pública.

Las autoridades requieren herramientas analíticas que permitan identificar patrones asociados a los accidentes más graves, predecir factores de riesgo y diseñar políticas públicas basadas en evidencia.

En este contexto, el equipo de analistas de datos de una entidad gubernamental ha contratado a los estudiantes del curso para desarrollar un análisis integral del comportamiento de los accidentes registrados en el dataset suministrado.

Los estudiantes deberán actuar como científicos de datos y analistas estadísticos, realizando:

- Limpieza y preparación de datos.
- Análisis descriptivo.
- Identificación de KPI's.
- Análisis inferencial.
- Validación estadística.
- Construcción de modelos predictivos.
- Interpretación crítica de hallazgos.
- Recomendaciones basadas en datos.

Objetivo General

Desarrollar un sistema completo de análisis estadístico y predictivo en Python que permita identificar factores asociados a la severidad de accidentes de tránsito mediante técnicas de analítica descriptiva, inferencial y modelos de regresión.

Objetivos Específicos

1. Realizar procesos de captura, limpieza y transformación de datos.
2. Aplicar estadística descriptiva para comprender el comportamiento general del dataset.
3. Diseñar KPI's relevantes para la interpretación de accidentalidad.
4. Validar supuestos estadísticos mediante pruebas de normalidad.
5. Aplicar pruebas de hipótesis paramétricas y no paramétricas.
6. Implementar análisis ANOVA para comparar grupos.
7. Construir modelos de regresión múltiple y logística.
8. Interpretar críticamente los resultados obtenidos.
9. Elaborar conclusiones orientadas a la toma de decisiones.

10. Documentar el proceso analítico utilizando estándares técnicos.

Dataset Suministrado

Archivo:

02_04_crash_severity.csv

Variables presentes en el dataset:

- Gravedad_Indicador_Tradicional
- Dia_Semana_Acc
- Localidad
- Clase_Acc
- Elemento_Choque
- Con_Bicicleta
- Con_Carga
- Con_Embriaguez
- Con_Huecos
- Con_Menores
- Con_Moto
- Con_Peaton
- Con_Persona_Mayor
- Con_Rutas
- Con_Tpi
- Con_Tpp
- Con_Velocidad
- Con_Sitp
- Con_Troncal
- Con_Alimentador
- Con_Zonal
- Con_Provisional
- Con_Articulado
- Con_Biarticulado
- Con_Padron_Dual
- Con_Servicio_Especial
- Con_Taxi

Cantidad aproximada de registros: 60.000

Requerimientos Técnicos Obligatorios

El proyecto debe desarrollarse en Python.

Librerías mínimas requeridas

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report
from sklearn.metrics import confusion_matrix
from sklearn.preprocessing import LabelEncoder
```

El uso de librerías adicionales deberá justificarse.

Estructura Obligatoria del Proyecto

El trabajo final deberá contener las siguientes secciones:

1. Portada
2. Introducción
3. Planteamiento del problema
4. Objetivos
5. Marco analítico y estadístico
6. Metodología
7. Limpieza y preparación de datos
8. Estadística descriptiva
9. KPI's y previsión
10. Pruebas de normalidad
11. Pruebas de hipótesis
12. Pruebas t
13. Wilcoxon y Mann-Whitney
14. ANOVA
15. Regresión múltiple
16. Regresión logística
17. Discusión crítica
18. Conclusiones
19. Recomendaciones
20. Referencias
21. Anexos de código

Desarrollo del Proyecto

FASE I — Comprensión del Dataset

Actividades obligatorias

1. Cargar el dataset.
2. Identificar dimensiones.
3. Identificar tipos de variables.
4. Detectar valores nulos.
5. Identificar inconsistencias.
6. Crear diccionario de datos.
7. Clasificar variables:
 - Cualitativas nominales
 - Cualitativas ordinales
 - Cuantitativas

Preguntas críticas obligatorias

- ¿Qué tan confiable parece el dataset?
- ¿Existen variables que puedan inducir sesgos?
- ¿La ausencia de datos puede afectar las conclusiones?
- ¿Qué implicaciones éticas tendría una mala interpretación de estos datos?

Código mínimo esperado

`df.info()`

`df.describe()`

`df.isnull().sum()`

FASE 2 — Limpieza y Transformación de Datos

Actividades obligatorias

1. Tratamiento de nulos.
2. Eliminación de duplicados.
3. Estandarización de variables categóricas.
4. Conversión de variables.
5. Codificación de variables categóricas.
6. Creación de variables derivadas.

Desarrollo crítico obligatorio

El estudiante deberá justificar:

- Por qué decidió eliminar o conservar datos.
- Qué impacto tiene la limpieza sobre el análisis.
- Cómo podrían alterarse los resultados dependiendo del tratamiento aplicado.

Ejemplo de análisis crítico esperado

"Eliminar registros con valores nulos puede reducir ruido estadístico; sin embargo, también puede generar pérdida de información relevante y afectar la representatividad de ciertos grupos poblacionales."

FASE 3 — Estadística Descriptiva

Actividades obligatorias

1. Medidas de tendencia central.
2. Medidas de dispersión.
3. Distribuciones de frecuencia.
4. Histogramas.
5. Boxplots.
6. Tablas dinámicas.
7. Correlaciones.

Variables sugeridas para análisis

- Severidad del accidente.
- Accidentes por localidad.
- Accidentes con motocicletas.
- Accidentes con peatones.
- Accidentes asociados a embriaguez.

Interpretación crítica obligatoria

No basta con mostrar gráficos.

Cada visualización debe responder:

- ¿Qué significa este comportamiento?
- ¿Qué posibles causas podrían explicar el patrón?
- ¿Qué riesgos sociales evidencia?
- ¿Qué decisiones podrían tomarse?

Ejemplo de análisis esperado

"La alta concentración de accidentes en determinadas localidades podría estar asociada no solo a densidad vehicular, sino también a problemas de infraestructura, control vial insuficiente o patrones de movilidad urbana deficientes."

FASE 4 — KPI's y Previsión

KPI's obligatorios

El estudiante deberá diseñar mínimo 10 KPI's.

Ejemplos:

- Porcentaje de accidentes con heridos.
- Tasa de accidentes con motocicletas.
- Porcentaje de accidentes con peatones.
- Índice de accidentalidad por localidad.
- Porcentaje de accidentes asociados a embriaguez.
- Proporción de accidentes por día de la semana.

Desarrollo obligatorio

Cada KPI debe incluir:

1. Fórmula.
2. Interpretación.
3. Visualización.
4. Importancia estratégica.
5. Posible aplicación real.

Preguntas críticas

- ¿Un KPI puede ser engañoso?
- ¿Qué ocurre si se interpreta fuera de contexto?
- ¿Cómo podrían manipularse indicadores estadísticos?

FASE 5 — Teorema del Límite Central y Normalidad

Actividades obligatorias

1. Seleccionar variables relevantes.
2. Aplicar pruebas de normalidad:
 - Shapiro-Wilk
 - Kolmogorov-Smirnov
3. Interpretar histogramas.
4. Analizar distribución.
5. Relacionar resultados con el TLC.

Código mínimo esperado

```
from scipy.stats import shapiro  
from scipy.stats import kstest
```

Interpretación crítica obligatoria

El estudiante deberá explicar:

- Por qué la normalidad es importante.
- Qué riesgos existen al usar pruebas paramétricas sin normalidad.
- Qué implicaciones tiene el tamaño de muestra.
- Por qué datasets grandes pueden aparentar normalidad.

Discusión profunda esperada

Se espera que el estudiante cuestione:

- ¿La estadística clásica siempre representa adecuadamente fenómenos reales?
- ¿La normalidad es una propiedad real o una simplificación matemática útil?

FASE 6 — Distribuciones y Pruebas de Hipótesis

Actividades obligatorias

1. Formular hipótesis nula y alternativa.
2. Seleccionar pruebas adecuadas.
3. Interpretar p-value.
4. Tomar decisiones estadísticas.
5. Explicar errores tipo I y II.

Ejemplos de hipótesis sugeridas

Hipótesis 1

H0: La presencia de motocicletas no influye en la severidad del accidente.

H1: La presencia de motocicletas sí influye en la severidad del accidente.

Hipótesis 2

H0: Los accidentes asociados a embriaguez tienen igual comportamiento que los demás accidentes.

H1: Los accidentes asociados a embriaguez presentan diferencias significativas.

Interpretación crítica obligatoria

No se aceptarán interpretaciones simples como:

"Se rechaza H0 porque $p < 0.05$ "

El estudiante deberá analizar:

- Implicaciones reales del hallazgo.
- Posibles sesgos.
- Limitaciones de inferencia.
- Relación entre significancia estadística y significancia práctica.

FASE 7 — Pruebas t

Actividades obligatorias

1. Comparar grupos.
2. Aplicar prueba t independiente.
3. Interpretar resultados.
4. Validar supuestos.

Ejemplo sugerido

Comparar severidad promedio entre accidentes:

- Con motocicleta.
- Sin motocicleta.

Desarrollo crítico obligatorio

El estudiante deberá responder:

- ¿Una diferencia estadística implica causalidad?
- ¿Existen variables ocultas?
- ¿Puede una correlación generar interpretaciones erróneas?

FASE 8 — Wilcoxon y Mann-Whitney

Actividades obligatorias

1. Identificar cuándo usar pruebas no paramétricas.
2. Comparar grupos no normales.
3. Justificar elección metodológica.

Ejemplo sugerido

Comparar severidad entre:

- Accidentes con peatones.
- Accidentes sin peatones.

Discusión crítica obligatoria

El estudiante deberá analizar:

- Diferencias entre enfoque paramétrico y no paramétrico.
- Limitaciones de los rankings estadísticos.
- Cuándo una prueba robusta es preferible.

FASE 9 — ANOVA

Actividades obligatorias

1. Comparar múltiples grupos.
2. Aplicar ANOVA.
3. Analizar diferencias entre localidades.
4. Realizar interpretación avanzada.

Ejemplo sugerido

Comparar niveles de severidad entre distintas localidades.

Desarrollo crítico obligatorio

El estudiante deberá discutir:

- ¿Por qué ciertos territorios presentan mayor severidad?
- ¿Los datos reflejan desigualdad urbana?
- ¿Qué factores externos podrían influir?

Profundización esperada

No se evaluará solamente el resultado numérico.

Se evaluará la capacidad de conectar el análisis estadístico con:

- Movilidad urbana.
- Infraestructura.
- Factores sociales.
- Políticas públicas.

FASE 10 — Regresión Múltiple

Actividades obligatorias

1. Construir modelo de regresión.
2. Seleccionar variables predictoras.
3. Interpretar coeficientes.
4. Analizar R^2 .
5. Detectar multicolinealidad.
6. Evaluar desempeño.

Variables sugeridas

Variable dependiente:

- Severidad del accidente.

Variables independientes:

- Presencia de moto.
- Embriaguez.
- Peatón.
- Día de la semana.
- Localidad.

Interpretación crítica obligatoria

El estudiante deberá analizar:

- ¿Qué variables realmente aportan?
- ¿Qué limitaciones tiene el modelo?
- ¿El modelo explica causalidad o asociación?
- ¿Qué tan útil sería este modelo en el mundo real?

Desarrollo avanzado esperado

Se espera discusión sobre:

- Sobreajuste.
- Interpretabilidad.
- Ética de modelos predictivos.
- Riesgos de automatización.

FASE II — Regresión Logística

Actividades obligatorias

1. Convertir severidad en variable binaria.
2. Entrenar modelo logístico.
3. Realizar matriz de confusión.
4. Calcular precisión.
5. Analizar recall y F1-score.
6. Interpretar probabilidades.

Ejemplo sugerido

Clasificar accidentes:

- Graves.
- No graves.

Desarrollo crítico obligatorio

El estudiante deberá responder:

- ¿Qué tan confiable es el modelo?
- ¿Qué consecuencias tendría un falso negativo?
- ¿Qué impacto social tendría usar este modelo?
- ¿Podría existir discriminación algorítmica?

Profundización obligatoria

Se espera análisis sobre:

- IA responsable.
- Sesgos algorítmicos.
- Interpretabilidad de modelos.
- Uso ético de predicciones.

Visualizaciones Obligatorias

El trabajo debe incluir mínimo:

- 5 histogramas.
- 5 boxplots.
- 5 gráficos de barras.
- 2 heatmaps.
- 2 scatterplots.
- 1 matriz de correlación.
- 1 matriz de confusión.

Requerimientos de Programación

El código debe incluir:

- Comentarios explicativos.
- Funciones.
- Modularización.
- Buenas prácticas.
- Limpieza visual.

Se evaluará:

- Legibilidad.
- Organización.
- Eficiencia.
- Documentación.
- Reproducibilidad.

Discusión Crítica Final

Esta sección tendrá un peso alto en la nota.

El estudiante deberá elaborar un análisis profundo sobre:

1. Limitaciones del dataset.
2. Posibles sesgos.
3. Restricciones estadísticas.
4. Interpretación responsable.
5. Riesgos de sobreinterpretación.
6. Diferencia entre correlación y causalidad.
7. Implicaciones sociales.
8. Uso ético de analítica.
9. Impacto de decisiones basadas en datos.
10. Rol de la Ingeniería de Sistemas en la analítica moderna.

Conclusiones

Las conclusiones deben:

- Integrar resultados estadísticos.
- Relacionar hallazgos.
- Proponer soluciones.
- Identificar oportunidades futuras.
- Argumentar críticamente.

No se aceptarán conclusiones superficiales.

Entregables

Entrega obligatoria

1. Documento final PDF.
2. Código fuente en Python.
3. Notebook Jupyter.
4. Base de datos trabajada.

Requisitos de Profundidad

El proyecto NO debe limitarse a ejecutar código.

Se evaluará especialmente:

- Capacidad analítica.
- Pensamiento crítico.
- Argumentación técnica.
- Interpretación estadística.
- Relación con problemas reales.
- Capacidad de cuestionar resultados.

Recomendaciones Técnicas

Se recomienda utilizar:

- Jupyter Notebook.
- Google Colab.
- VSCode.
- GitHub.

Posibles Líneas de Profundización

Los estudiantes podrán incluir elementos adicionales como:

- Machine Learning.
- Árboles de decisión.
- Random Forest.
- Clustering.
- Dashboards.
- Streamlit.
- Power BI.
- Integración con APIs.

Preguntas de Reflexión Final

1. ¿Los datos representan la realidad completa?
2. ¿Qué información falta?
3. ¿Qué tan objetiva es la analítica?
4. ¿Puede un modelo matemático comprender fenómenos humanos complejos?
5. ¿Qué responsabilidad ética tiene un ingeniero de sistemas al construir modelos predictivos?
6. ¿Qué riesgos existen cuando las decisiones públicas dependen exclusivamente de algoritmos?
7. ¿Cómo evitar interpretaciones estadísticas engañosas?
8. ¿Qué diferencia existe entre automatizar decisiones y comprender fenómenos?

Nota Final

Este trabajo busca integrar programación, estadística y pensamiento crítico. La verdadera analítica de datos no consiste únicamente en generar gráficos o ejecutar algoritmos, sino en comprender el contexto, interpretar correctamente la información y reconocer las limitaciones de los modelos matemáticos frente a la complejidad del mundo real.

El ingeniero moderno debe ser capaz no solo de construir soluciones tecnológicas, sino también de cuestionar críticamente los datos y las decisiones derivadas de ellos.

Éxitos